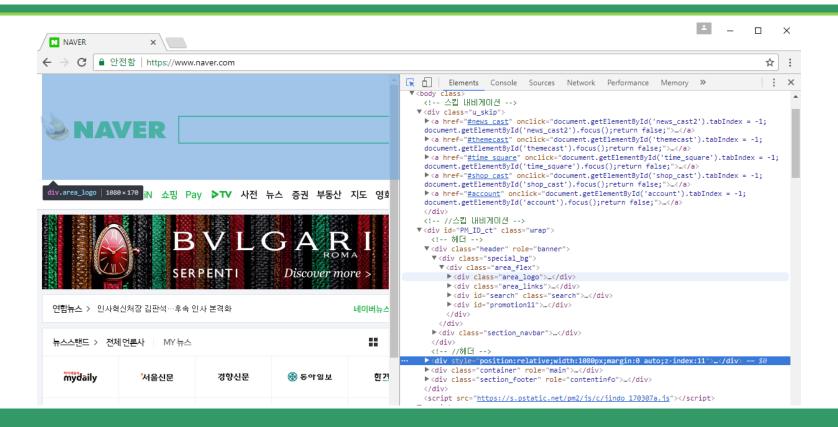
Web Crawling - Basics

감성분석

박진수 교수

Big Data Institute, Seoul National University

웹 구조 이해하기



브라우저 설치

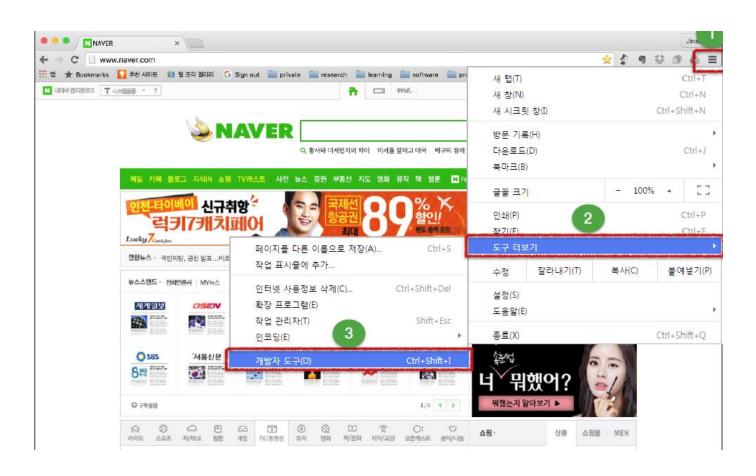
· 본 강의는 구글 크롬(google chrome) 브라우저를 기준으로 진행되니 크롬 브라우저가 없을 경우 컴 퓨터에 이를 설치한다

- 다운로드: https://www.google.co.kr/chrome/browser/desktop/index.html



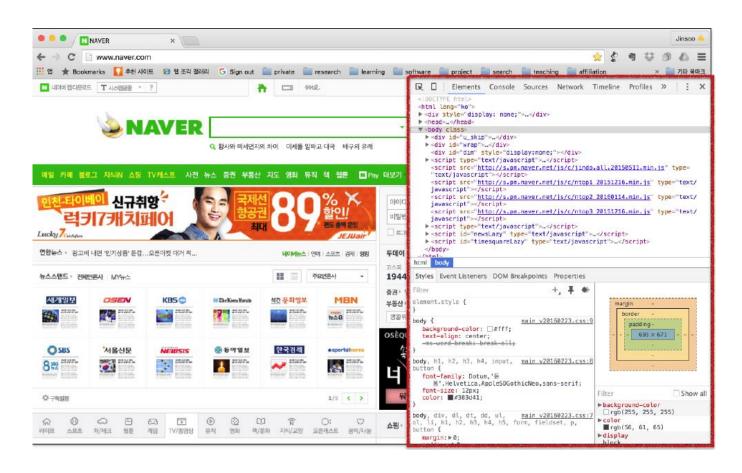
개발자 도구(Developer Tools)

- · 웹의 구조를 파악하기 위해서 크롬 브라우저의 '개발자 도구'를 활용한다
 - 단축키: Ctrl + Shift + I



개발자 도구(Developer Tools)

- · 웹의 구조를 파악하기 위해서 크롬 브라우저의 '개발자 도구'를 활용한다
 - 단축키: Ctrl + Shift + I



- · 웹 페이지 제작을 위한 마크업 언어
 - 마크업 언어(Markup Language): 태그, 속성 등을 이용하여 문서나 데이터의 구조를 정의하고 표현하는 언어
 - HTML은 제목, 단락, 목록 등과 같은 본문을 위한 구조적 의미를 나타내는 것 뿐만 아니라 링크, 인용과 그 밖의 항목으로 구조적 문서를 만들 수 있는 방법을 제공
 - HTML은 웹 페이지 콘텐츠 안의 꺾쇠 괄호(<>)에 둘러싸인 "태그"로 되어있는 HTML 요소 형태로 작성

```
<title> Hello HTML </title>  Hello World!
```

<!DOCTYPE html>
<html>
<hr color="block" col

HTML

- · HTML 요소: 가장 보편적인 형태는 세 가지 구성 요소를 가진다. "태그" 한 쌍, "속성", 그리고 "콘텐츠"
 - 태그(tag): 요소를 구분할 수 있도록 하는 이름표. 일반적으로 시작 태그(<tag>)와 종료 태그(</tag>) 한 쌍으로 구성된다
 - 속성(attribute): 태그들의 특성을 부여
 - 콘텐츠(contents): 화면에 표시되는 문자와 그래픽 정보 → **크롤링을 할 때 프로그래머의 관심의 대상**

- · HTML 마크업 요소의 형태
 - 구조적 마크업: 본문의 목적을 표현
 - 제목(title), 문단(p), 표(table) 등
 - 표현적 마크업: 기능에 관계없이 본문의 외관을 표현
 - 굵게(b), 이탤릭(i) 등

- 하이퍼텍스트 마크업: 다른 문서와 연결시켜주는 문서의 부분
 - 링크(a)

 한국어 위키백과

· 주요 HTML 요소

HTML 요소	기능	비고
 	줄바꾸기	빈 태그(끝 태그가 없다)
	단락바꾸기	
<h>></h>	제목(heading)	h1, h2 등으로 표현
<center></center>	가운데 정렬	
	폰트를 바꿈	
<u >< i>< i></u >	순서없는 목록	기본: 까만 동그라미
<0 >< i>< i>	순서있는 목록	기본: 숫자
	표 만들기	
	행	에 넣는다
<	열	에 넣는다

• 속성

- 대부분의 요소 속성들은 "이름-값" 형태이고 "="으로 구분한다.
 - 요소의 시작 태그 내에서 요소의 이름 다음에 쓰인다
- 일반적인 속성
 - id: 요소에 대한 문서 전체의 고유 식별자를 제공
 - class: 유사한 요소를 분류하는 방법을 제공
 - style: 특정 요소에 표현적 속성을 제공
 - title: 요소에서 숨겨진 뜻을 설명하는 글을 첨부

<abbr id="anId" class="aClass" style="color:blue;" title="하이퍼텍스트 마크업 언어">
HTML</abbr>

· Hello world 프로그램 in HTML

· 참고 - More HTML & CSS: https://www.codecademy.com/learn/web

실습 0 – HTML 문서 생성하기

```
<html>
<head id="html_head">
<head id=
```

실습 1-1-1. HTML 문서 생성하기

```
<!DOCTYPE html>
<html>
<body>
<h1>My First Heading</h1>
My first paragraph.
</body>
</html>
```

실습 1-1-2. HTML 문서 생성하기

```
<!DOCTYPE html>
<html>
<body>

<a href="https://www.w3schools.com">This is a link</a>
</body>
</html>
```

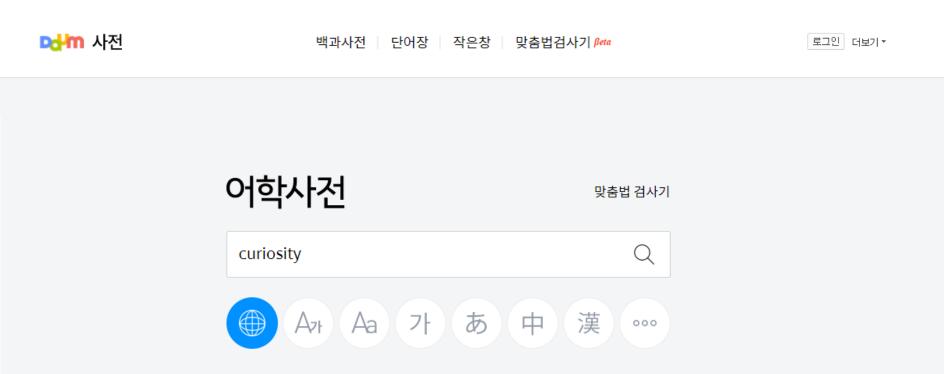
실습 1-1-3. HTML 문서 생성하기

```
<!DOCTYPE html>
<html>
<body>
This is a paragraph.
This is a paragraph.
This is a paragraph.
</body>
</html>
```

실습 1-1-4. HTML 문서 생성하기

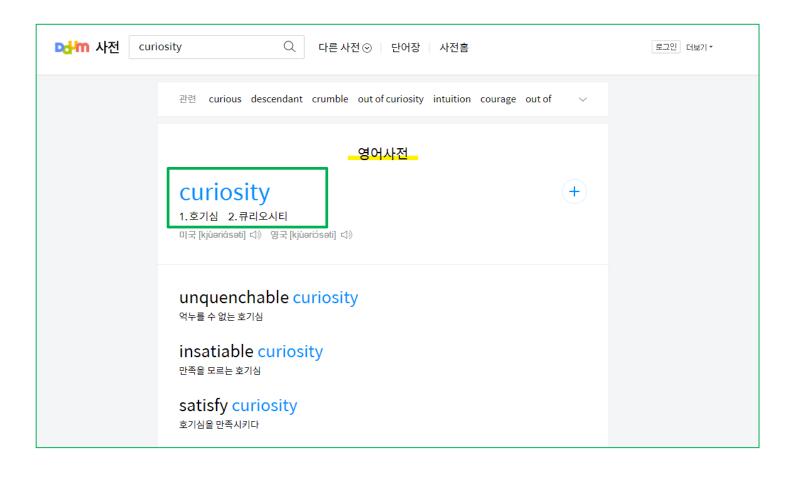
```
<!DOCTYPE html>
<ht.ml>
<body>
I am normal
I am red
I am blue
I am big
</body>
</html>
```

실습 2 – 다음 사전



실습 1-2-1. 단어의 검색 결과 출력하기

- · 다음 어학사전(<u>http://dic.daum.net/index.do?dic=all</u>)에 'curiosity' 단어를 검색하였을 때 출력 되는 화면에서 가장 상단의 결과를 출력한다
 - 영어 단어의 의미(본 예제에서는 '1. 호기심 2. 큐리오시티')를 출력한다



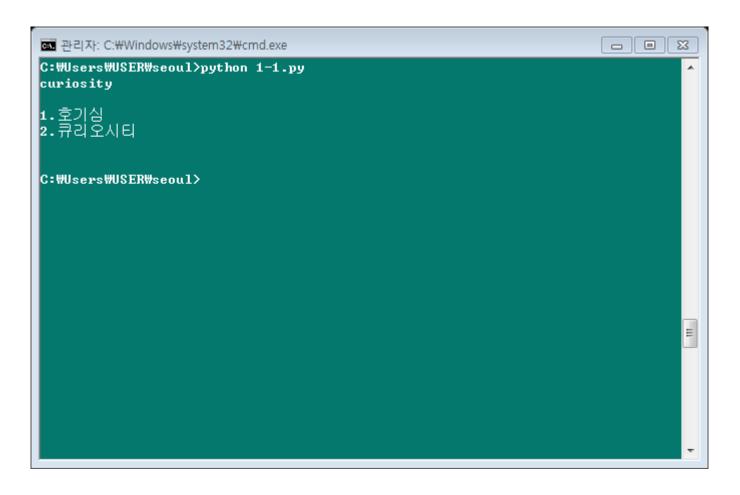
실습 1-2-1. 단어의 검색 결과 출력하기

· TIPS

- 가져오고자 하는 텍스트의 다른 HTML 구성요소와 구분되는 특성(CSS style)을 잘 생각해 본다
- 가장 상단에 있는 데이터임을 고려하면서 HTML 파싱 결과를 어떻게 슬라이싱(slicing)할 것인지 고민해 본다

실습 1-2-1. 단어의 검색 결과 출력하기

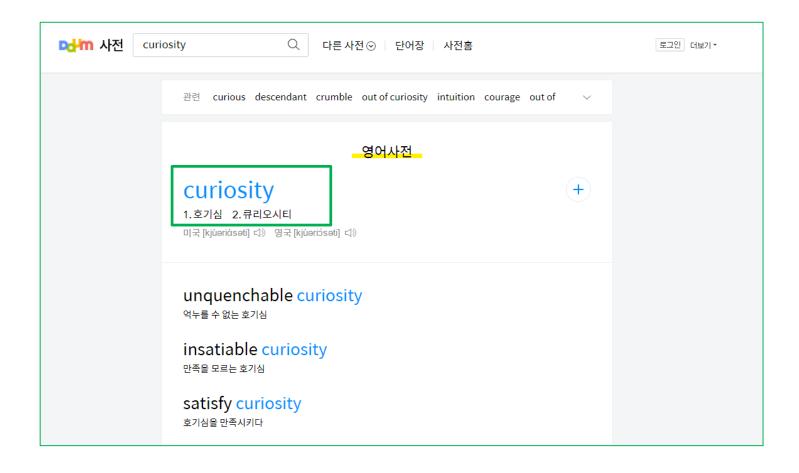
· 출력 결과



실습 1-2-2. 여러 단어의 검색 결과 출력하기

· 다음 어학사전(<u>http://dic.daum.net/index.do?dic=all</u>)에 'curiosity', 'killed', 'the', 'cat' 4개 단어를 검색 하였을 때 출력 되는 화면에서 가장 상단의 결과를 출력한다

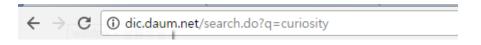
- 영어 단어의 의미를 출력한다



실습 1-2-2. 여러 단어의 검색 결과 출력하기

· TIPS

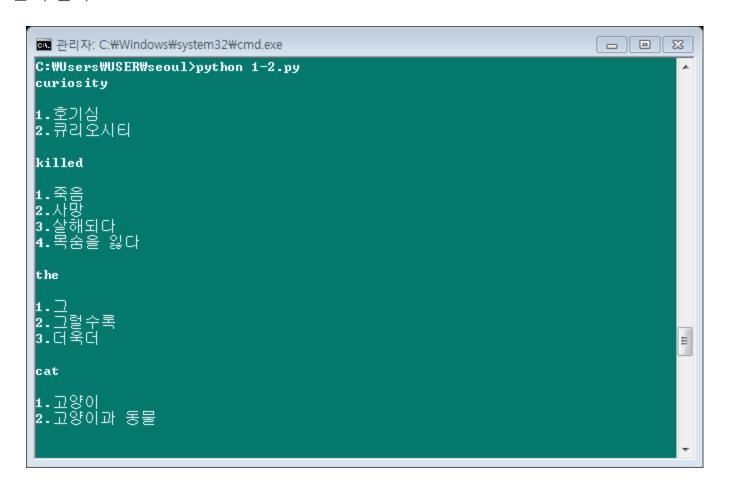
- 초기 화면에서 몇 개 단어를 검색해 보면서 URL 구조를 잘 생각해 본다



- for 문을 활용해 여러 단어를 돌아가면서 데이터를 출력한다

실습 1-2-2. 여러 단어의 검색 결과 출력하기

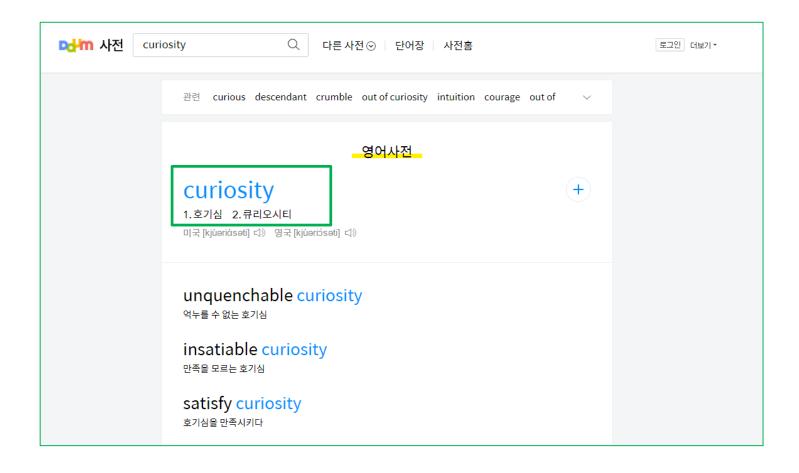
· 출력 결과



실습 1-2-3. 여러 단어의 검색 결과 저장하기

· 다음 어학사전(<u>http://dic.daum.net/index.do?dic=all</u>)에 'curiosity', 'killed', 'the', 'cat' 4개 단어를 검색 하였을 때 출력 되는 화면에서 가장 상단의 결과를 텍스트 파일에 저장한다

- 영어 단어의 의미를 저장한다



실습 1-2-3. 여러 단어의 검색 결과 저장하기

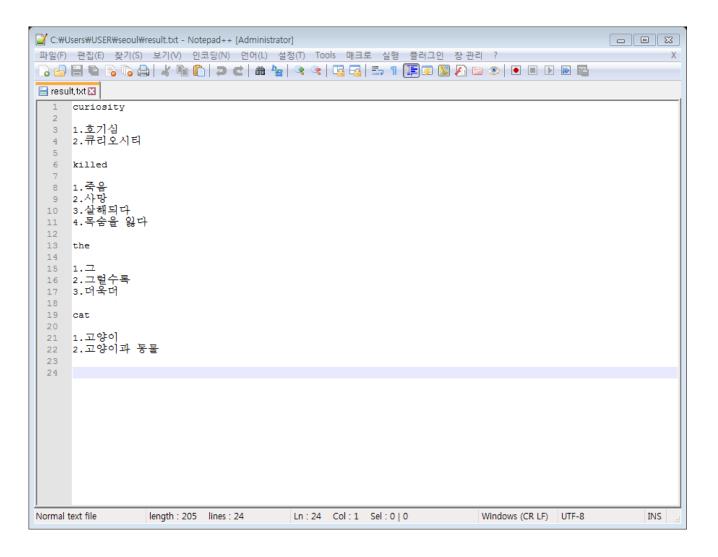
·TIPS

- 파이썬의 open 함수를 사용해 텍스트 파일로 저장한다

- 한글 저장을 위해 인코딩을 'utf-8'로 설정한다

실습 1-2-3. 여러 단어의 검색 결과 저장하기

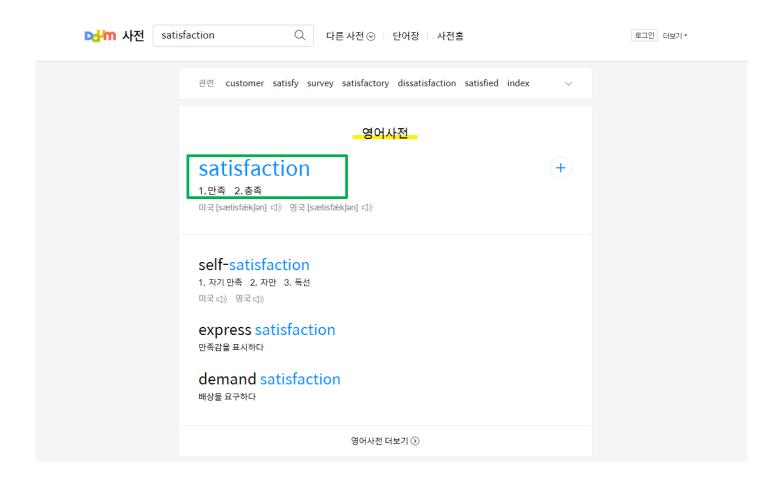
ㆍ 저장 결과



실습 1-2-4. 여러 단어를 불러와 검색 결과 저장하기

· 다음 어학사전(http://dic.daum.net/index.do?dic=all)에 텍스트 파일(data.txt)에 있는 각 단어를 검색하였을 때 출력 되는 화면에서 가장 상단의 결과를 텍스트 파일에 저장한다

- 영어 단어의 의미를 저장한다



실습 1-2-4. 여러 단어를 불러와 검색 결과 저장하기

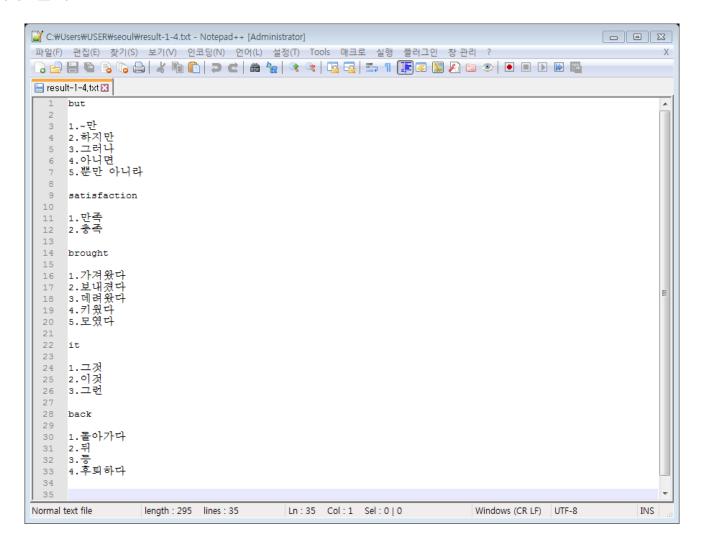
· TIPS

- 텍스트 파일의 내용을 불러올 때 readlines 함수를 사용한다

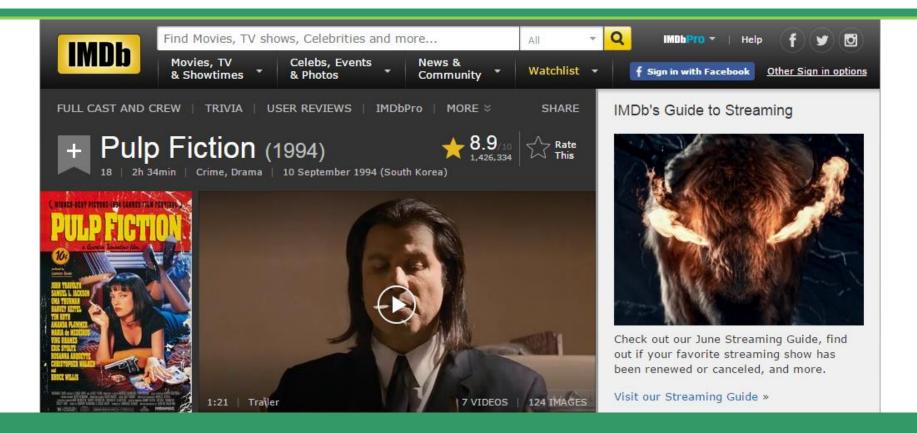
- 한글 저장을 위해 인코딩을 'utf-8'로 설정한다

실습 1-2-4. 여러 단어를 불러와 검색 결과 저장하기

ㆍ 저장 결과



실습 3 - IMDb



실습 1-3-1. 영화 정보 출력하기

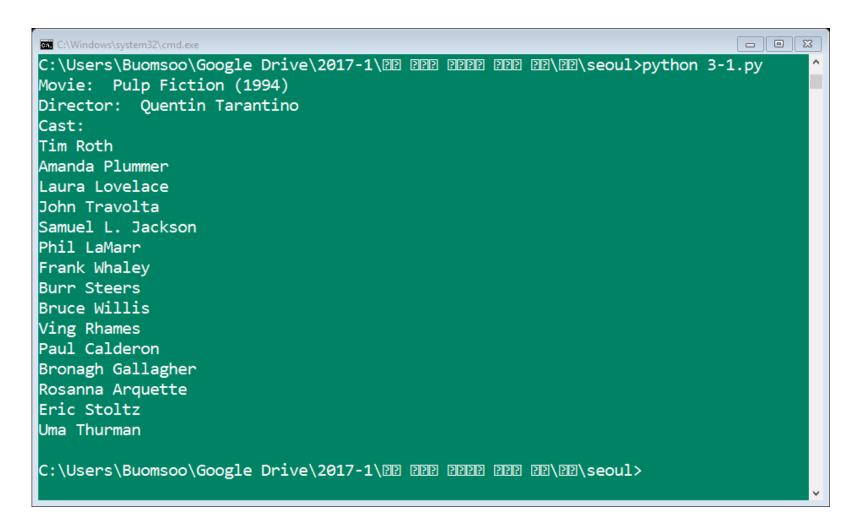
· IMDb 사이트에서 영화 펄프 픽션 페이지(<u>http://www.imdb.com/title/tt0110912/?ref_=nv_sr_1</u>)에서 펄 프 픽션 영화의 제목(title)과 감독(director), 그리고 출연 배우(cast)를 출력한다





실습 1-3-1. 영화 정보 출력하기

· 출력 결과



실습 1-3-2. 여러 영화 정보 저장하기

- · 영화 펄프 픽션(Pulp Fiction), 포레스트 검프(Forrest Gump), 그리고 다크 나이트(The Dark Knight)의 제목(title)과 감독 이름(director)를 텍스트 파일에 저장한다
 - 영화 하나당 한 줄씩 출력되도록 한다



실습 1-3-2. 여러 영화 정보 저장하기

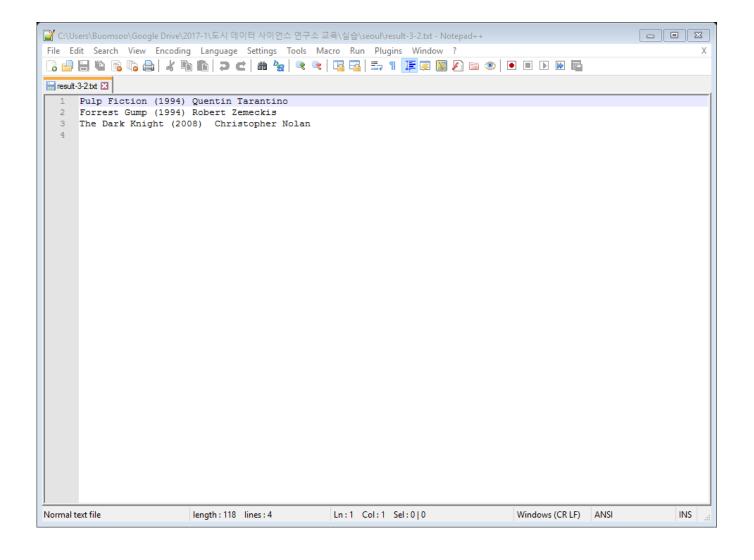
· TIPS

- 영화가 달라짐에 따라 각 영화 정보의 URL이 어떻게 변하는지 잘 살펴본다



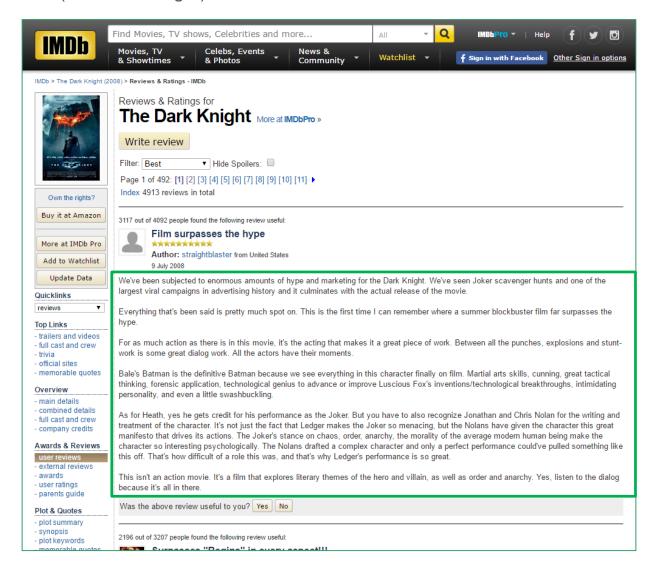
실습 1-3-2. 여러 영화 정보 저장하기

ㆍ 저장 결과



실습 1-3-3. 영화 리뷰 출력하기

· 영화 다크 나이트(The Dark Knight)의 리뷰 페이지에 들어가 첫 번째 리뷰 내용을 출력해 보자



실습 1-3-3. 영화 리뷰 출력하기

· TIPS

- Table의 구성요소 중 'p' 태그를 가진 요소를 모두 찾는다
- 'p' 태그 중 내용에 'This review may contain spoilers' 및 'Add another review'가 포함된 태그를 제외하고 출력한다
- if문과 break를 활용해 첫 번째 리뷰만 출력한다
- replace함수를 이용해 불필요한 공백을 제거한다('\r', '\n' 등)

실습 1-3-3. 영화 리뷰 출력하기

· 출력 결과

C:\Windows\system32\cmd.exe C:\Users\Buomsoo\Google Drive\2017-1\22 222 222 222 22\22\seoul>python 3-3.py We've been subjected to enormous amounts of hype and marketing for the Dark Knight. We've seen Joker scavenger hunts and one of the largest viral campaigns in advertising history and it culminates with the actual release of the movie.Everything that's been said is pret ty much spot on. This is the first time I can remember where a summer blockbuster film far surpasses the hype. For as much action as there is in this movie, it's the acting that mak es it a great piece of work. Between all the punches, explosions and stunt-work is some gr eat dialog work. All the actors have their moments.Bale's Batman is the definitive Batman because we see everything in this character finally on film. Martial arts skills, cunning, great tactical thinking, forensic application, technological genius to advance or improve Luscious Fox's inventions/technological breakthroughs, intimidating personality, and even a little swashbuckling. As for Heath, yes he gets credit for his performance as the Joker . But you have to also recognize Jonathan and Chris Nolan for the writing and treatment of the character. It's not just the fact that Ledger makes the Joker so menacing, but the No lans have given the character this great manifesto that drives its actions. The Joker's st ance on chaos, order, anarchy, the morality of the average modern human being make the cha racter so interesting psychologically. The Nolans drafted a complex character and only a p erfect performance could've pulled something like this off. That's how difficult of a role this was, and that's why Ledger's performance is so great. This isn't an action movie. It' s a film that explores literary themes of the hero and villain, as well as order and anarc hy. Yes, listen to the dialog because it's all in there.

실습 1-3-4. 영화 리뷰 저장하기

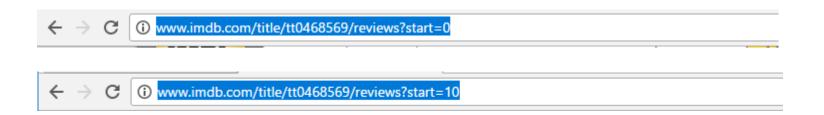
- · 영화 다크 나이트(The Dark Knight)의 첫 번째 부터 10번째 페이지까지의 리뷰를 텍스트 파일에 저장 한다
 - 총 100개의 리뷰가 저장되어야 한다



실습 1-3-4. 영화 리뷰 저장하기

· TIPS

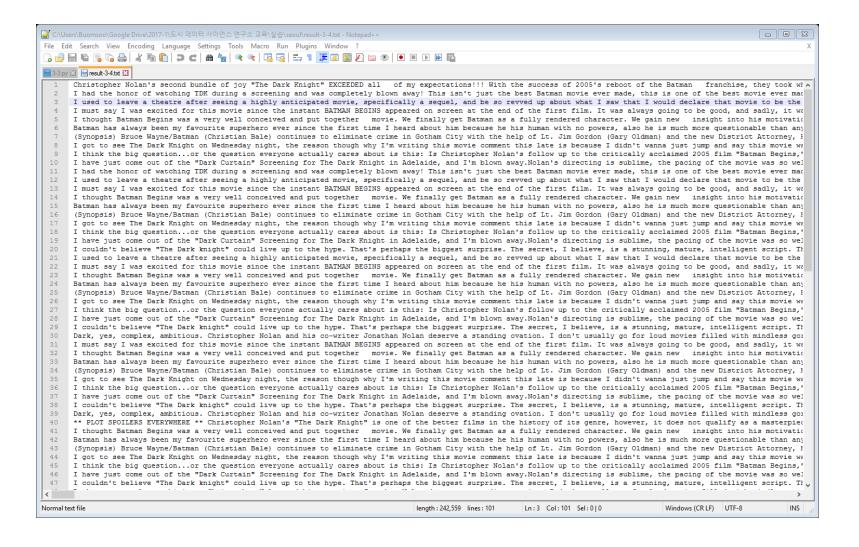
- 영화 리뷰 페이지의 페이지 번호를 바꾸어 가면서 URL 구조를 세심히 살펴보자



- While 문을 활용해 영화 리뷰를 페이지마다 모두 저장한다(while문 마지막에 구문 탈출 조건 명시)
- replace함수를 이용해 불필요한 공백을 제거한다('\r', '\n' 등)
- 파일을 저장할 때 인코딩(encoding) 설정을 꼭 'utf-8'으로 한다

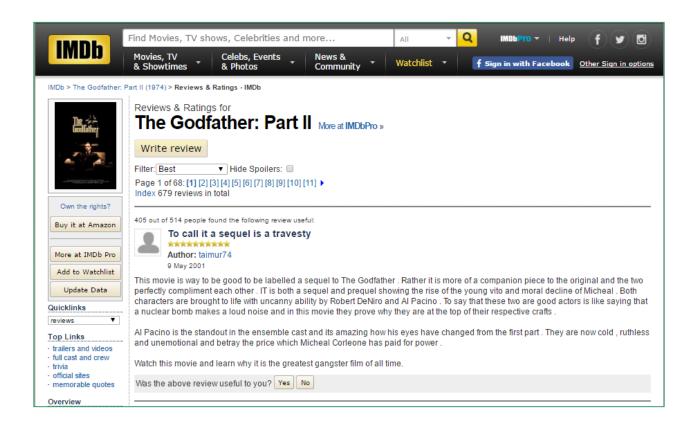
실습 1-3-4. 영화 리뷰 저장하기

· 저장 결과



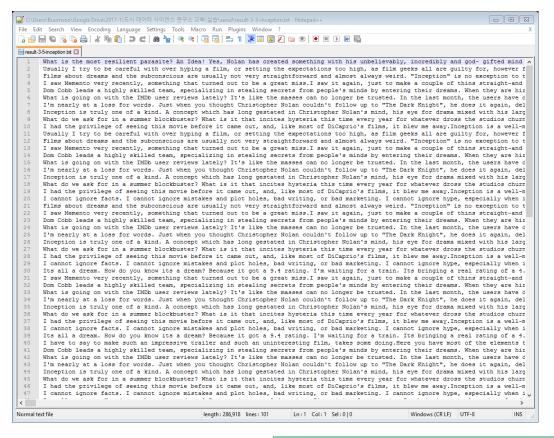
실습 1-3-5. 영화 리뷰 저장하기(2)

- · 자신이 좋아하는 영화를 3개 이상 골라 3-4의 코드를 조금씩 바꾸어 영화 리뷰를 각각 다른 텍스트 파일에 저장해 본다
 - 리뷰를 영화 별로 최소한 100개 이상 수집한다



실습 1-3-5. 영화 리뷰 저장하기(2)

ㆍ 저장 결과



result-3-5-inception	21/06/2017 17:40	Text Document	281 KB
result-3-5-old_boy	21/06/2017 17:42	Text Document	181 KB
result-3-5-whiplash	21/06/2017 17:41	Text Document	216 KB